




Trabajo de Fin de Máster

Máster en Data Science e
Inteligencia Artificial

**Predicción del abandono laboral
y su impacto económico:**

Un modelo de Machine Learning
para optimizar la retención de
talento dentro de la empresa

EBIS

Business Techschool

Presentado por: Kelvin Barreto Cali

Septiembre 2025

Índice

1. Introducción
 - 1.1 Objetivo del proyecto
 - 1.2 Contexto y problemática del abandono de empleados
 - 1.3 Impacto económico y esperado en la organización
2. Análisis exploratorio de datos
 - 2.1 Descripción de los datos
 - 2.2 Preparación y limpieza de datos
 - 2.3 Variables utilizadas (predictoras y etiqueta)
 - 2.4 Modelos de predicción seleccionados
3. Resultados de los Modelos
 - 3.1 Métricas de rendimiento
 - 3.2 Probabilidades de abandono obtenidas
 - 3.3 Segmentación de riesgo (bajo, medio, alto)
4. Análisis de influencia de Variables
 - 4.1 Interpretación con valores SHAP
 - 4.2 Principales factores que influyen en el abandono
 - 4.3 Variables destacadas
5. Conclusiones y Recomendaciones
 - 5.1 Conclusiones clave
 - 5.2 Impacto económico estimado
 - 5.3 Recomendaciones estratégicas para reducir el abandono
 - 5.4 Posibles mejoras y trabajo futuro
6. Bibliografía

1. Introducción

1.1 Objetivo del proyecto

El objetivo principal de este proyecto es predecir la probabilidad de abandono de las personas trabajadoras dentro de la organización en la que actualmente estoy trabajando, con el fin reportar al departamento directivo anticipos de bajas laborales y facilitar el diseño de estrategias proactivas de retención del talento.

Además de la predicción, este estudio aborda la identificación de los factores que más influyen en la decisión de abandonar la empresa, tales como aspectos económicos, nivel de satisfacción laboral, oportunidades de promoción y condiciones personales o profesionales. De esta manera, se busca no solo anticipar las salidas, sino también comprender qué motiva a los empleados a dejar su puesto de trabajo.

La elección de este tema está estrechamente vinculada con mi función como responsable de Recursos Humanos, lo que otorga al proyecto un enfoque práctico y alineado con las necesidades reales de la organización.

1.2 Contexto y problemática del abandono de los empleados

La rotación de personal es uno de los principales desafíos a los que se enfrentan actualmente las organizaciones, especialmente en entornos laborales caracterizado por la alta competitividad y la búsqueda constante de talento especializado. El abandono de empleados no solo supone la pérdida de capital humano, sino también conlleva costes directos e indirectos significativos, tales como:

- Gastos derivados de procesos de selección y contratación de nuevos empleados.
- Inversión en formación y adaptación de nuevos integrantes.
- Pérdida temporal de productividad y conocimiento acumulado.

En el contexto de esta organización, la problemática se intensifica debido a que:

- Se observan patrones de abandono en determinados perfiles, especialmente en etapas tempranas de antigüedad.
- No existe un sistema consolidado que nos permita anticiparnos al abandono y establecer planes preventivos individualizados.

1.3 Impacto económico y esperado en la organización

El abandono de empleados no solo implica la pérdida de talento, sino también un coste económico directo y significativo para la organización. Según el artículo de referencia de Toggl ([Cost of Hiring an Employee](#)), las empresas destinan entre el 15% y el 20% del salario anual de un empleado para cubrir los gastos asociados a la contratación de un nuevo candidato.

Estos costes incluyen procesos de selección, incorporación, formación inicial y la pérdida temporal de productividad hasta que la nueva persona alcanza el rendimiento esperado.

A partir de esta referencia, surge una pregunta clave para este proyecto: *¿Cuánto dinero podría ahorrar la organización mediante una mejor estrategia de retención de empleados?*

Este estudio buscará dar una respuesta a esta cuestión, cuantificado el impacto económico del abandono en el contexto específico de la organización y proponiendo un modelo predictivo que permita reducir la rotación y optimizar los recursos destinados a la gestión de talento.

2. Análisis exploratorio de los datos

2.1 Descripción de los datos

Para el desarrollo de este proyecto se ha trabajado con un conjunto de datos internos de la organización que recoge información histórica sobre las personas trabajadoras a lo largo de los últimos cinco años. Este dataset incluye tanto a quienes continúan formando parte de la empresa como a aquellos que han causado baja voluntaria durante dicho período, proporcionando una base representativa para el análisis.

Con el fin de garantizar el cumplimiento de la normativa en materia de protección de datos, toda la información personal ha sido debidamente anonimizada, asegurando la confidencialidad y el uso exclusivamente estadístico de los registros.

Las variables contenidas en el dataset abarcan distintas dimensiones relevantes para el análisis:

- **Datos sociodemográficos:** edad, estado civil, grupo profesional
- **Datos económicos:** salario mensual
- **Datos laborales:** referencia (código para identificar al trabajador), antigüedad en la empresa, promociones internas, distancia al centro de trabajo, departamento asignado, equipo de trabajo y ubicación
- **Indicadores de satisfacción:** encuestas de satisfacción laboral
- **Etiqueta objetivo (perfil):** indica si la persona abandonó la empresa (0) o permanece actualmente (1).

En total, el conjunto de datos está compuesto por:

- Número total de registros: 223
- Número de variables totales (antes de preprocesar): 211
- Distribución de la etiqueta objetivo:
 - Abandono (0): 119 personas, 56%
 - Permanencia (1): 92 personas, 43%

Este dataset constituye la base para la fase de modelado predictivo y posterior análisis de influencia de variables, que se detallaran en los siguientes apartados.

2.2 Preparación y limpieza de datos

Antes de proceder al entrenamiento del modelo predictivo, se llevó a cabo un proceso exhaustivo de preparación y limpieza de los datos, con el objetivo de garantizar su calidad, coherencia y adecuación para el análisis.

Este proceso fue una de las etapas más complejas del proyecto, ya que los datos originales no estaban ordenados, presentaban formatos heterogéneos y carecían de una estructura unificada. Fue necesario invertir un esfuerzo considerable en su reorganización y normalización para hacerlos aptos para el modelado.

Las principales tareas realizadas fueron:

1. Revisión de la completitud y consistencia de los datos
 - a. Identificación de valores nulos, inconsistentes o duplicados.

	Number of Nulls	Percentage
Referencia	0	0.00
perfil	0	0.00
genero	0	0.00
jornada	0	0.00
equipo	0	0.00
ubicacion	0	0.00
nivel_estudios	6	2.69
estado_civil	2	0.90
edad	2	0.90
antiguedad_empresa	5	2.24
grupo_profesional	12	5.38
salario_mensual	11	4.93
departamento	2	0.90
distancia_trabajo_km	0	0.00
promociones	0	0.00
satisfaccion	0	0.00

Número de valores nulos y su porcentaje. Elaboración propia

- b. Se aplicaron técnicas de imputación de valores cuando la información faltante era recuperable sin comprometer la calidad del análisis. En los casos donde los registros presentaban ausencia significativa de datos o inconsistencias estructurales, se procedió a su eliminación. En particular, se decidió excluir todos los registros correspondientes al departamento “BECARIO”, ya que estos presentaban información incompleta de manera sistemática y, además, su inclusión no aportaba valor relevante para el objetivo del modelo de predicción.
2. Tratamiento de valores atípicos
 - a. Detección de outliers en variables clave como salario, edad o distancia.
3. Homogeneización de formatos y estructuras
 - a. Unificación de tipos de datos (por ejemplo, transformar columnas de texto a categóricas, transformación de las variables **nivel de estudios**, **perfil**, **género**, **jornada** y **ubicación** en variables numéricas) con el objetivo de reducir la dimensionalidad.
4. Codificación de variables categóricas
 - a. Transformación de variables como **equipo**, **departamento**, **estado civil** y **grupo profesional** mediante one-hot encoding.

5. Escalado de variables numéricas
 - a. Normalización de variables como edad, salario mensual, antigüedad en la empresa, distancia al trabajo, promociones y satisfacción laboral mediante MinMaxScaler, escalándolas en el rango [0,1].
6. División en conjuntos de entrenamiento y prueba
 - a. Para evitar sesgos en la evaluación, se separaron los datos en un 80% para entrenar el modelo y un 20% para evaluarlo, utilizando muestreo estratificado para respetar la distribución real de la variable objetivo.

2.3 Variables utilizadas (predictoras y etiqueta)

El modelo predictivo se entrenó utilizando una selección de variables relevantes que representan diferentes dimensiones de la realidad laboral de la organización. Estas variables fueron elegidas en base a su disponibilidad, su potencial relación con el abandono y su coherencia tras el proceso de preparación y limpieza de datos.

Las **variables independientes (X)** utilizadas en el modelo se agrupan en tres grandes categorías. En primer lugar, se consideraron variables demográficas, como la edad actual del empleado y su estado civil, codificado mediante variables dummy. En segundo lugar, se incluyeron variables laborales y organizativas, entre ellas la antigüedad en la empresa (años de permanencia), el grupo profesional, el departamento, el equipo asignado, y el número de promociones obtenidas. Finalmente, se incorporaron variables económicas y de satisfacción, que abarcan el salario mensual, la distancia estimada entre el domicilio y el centro de trabajo, y el nivel de satisfacción laboral medido a través de encuestas internas.

Variable dependiente (Y)

La etiqueta objetivo utilizada para el modelado fue la variable **perfil**, con codificación binaria:

- 0 = abandono: empleados que han causado baja en la organización
- 1 = permanencia: empleados que continúan en la organización

Esta estructura permitió entrenar el modelo para predecir la probabilidad de que un/a trabajador/a abandone la empresa, asignando a cada registro un valor probabilístico en lugar de una clasificación rígida.

df_procesado

	Referencia	perfil	genero	jornada	equipo	ubicacion	nivel_estudios	estado_civil	edad	antiguedad_empresa	grupo_profesional	salario_mensual	departamento	distancia_trabajo_km	promociones	satisfaccion
0	TRB-00000002	1	1	1	SEVILLA	1	1.0	CASADO	46	25	6.0	3617	DIRECCION	10	3	4
1	TRB-00000005	0	0	1	SEVILLA	1	4.0	CASADO	48	10	5.0	2562	RESPONSABLE DE AREA	14	2	2
2	TRB-00000007	1	0	1	ADMINISTRACION	1	4.0	CASADO	50	24	6.0	3605	DIRECCION	6	3	3
3	TRB-00000008	1	0	1	ORIENTE MEDIO	0	3.0	SOLTEROIA	50	24	6.0	3696	DIRECCION	8	3	3
4	TRB-00000009	1	0	1	MADRID	1	4.0	SOLTEROIA	48	24	6.0	3228	REFERENTES	9	3	3
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
216	TRB-00000243	1	0	1	EL SALVADOR	0	4.0	SOLTEROIA	27	0	2.0	2024	TECNICAS	12	0	3
219	TRB-00000246	1	0	1	EUSKADI	1	4.0	SOLTEROIA	29	0	2.0	2114	TECNICAS	10	0	3
220	TRB-00000247	1	0	1	BARCELONA	1	3.0	SOLTEROIA	25	0	2.0	2012	TECNICAS	14	0	4
221	TRB-00000248	1	0	1	VALENCIA	1	4.0	SOLTEROIA	30	0	3.0	2186	TECNICAS	8	0	3
222	TRB-00000249	1	0	1	VALENCIA	1	4.0	SOLTEROIA	40	0	4.0	2477	TECNICAS	19	0	3

211 rows x 16 columns

Variables utilizadas del dataset. Elaboración propia

2.4 Modelos de predicción seleccionados

Para abordar la predicción del abandono laboral, se entrenaron y evaluaron tres modelos de clasificación supervisada, con el objetivo de comparar su rendimiento y seleccionar el más adecuado para este proyecto.

Los modelos elegidos fueron:

- 1) **Regresión Logística:** Nos ayuda a estimar la probabilidad de que un evento ocurra (por ejemplo, abandono = 1) mediante la función sigmoide:

$$P(y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n)}}$$

Donde:

- $X = (x_1, x_2, \dots, x_n)$ son las variables predictoras.
- β_0 es la intercepción.
- β_i son los coeficientes que indican la influencia de cada variable

- 2) **Random Forest:** es un conjunto de (ensamble) de árboles de decisión. Cada árbol se entrena sobre una muestra aleatoria del dataset (bagging) y la predicción final es el **promedio de probabilidades** (para clasificación, mayoría de votos).

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T h_t(X)$$

Donde:

- a. T es el número de árboles
- b. $h_t(X)$ es la predicción de cada árbol individual

- 3) **XGBoost (Extreme Gradient Boosting):** Es un algoritmo de boosting que entrena árboles de manera secuencial, corrigiendo los errores de los anteriores mediante gradiente descendente.

$$\text{Obj}(\theta) = \sum_{i=1}^n L(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k)$$

Donde:

- a. L mide el error de predicción
- b. $\Omega f(k)$ penaliza la complejidad de los árboles para evitar sobreajuste
- c. Cada nuevo árbol $f(k)$ se ajusta para minimizar el gradiente del error.

3. Resultados de los modelos

3.1 Métricas de rendimiento

Para evaluar el desempeño de los modelos entrenados – **Regresión Logística, Random Forest y XGBoost** – se utilizaron métricas clásicas de clasificación: Accuracy, Precisión, Recall, F1-score y AUC-ROC, junto con las matrices de confusión.

Dado que 1 indica permanencia en la empresa y 0 abandono, el objetivo principal es identificar correctamente a los empleados que abandonan (clase 0), ya que sobre ellos se desea actuar preventivamente.

Del análisis de las matrices de confusión se identifica que:

- **Regresión Logística:** Identifica correctamente 21 abandonos y 14 permanencias, pero presenta 5 falsos positivos, es decir, clasifica como abandono a personas que realmente permanecen.
- **Random Forest:** Mejora significativamente la clasificación, con solo 1 falso positivo, y mayor acierto tanto en abandonos (22) como en permanencias (18).
- **XGBoost:** Ofrece el mejor rendimiento, sin falsos positivos y solo 2 falsos negativos (casos de abandono clasificados erróneamente como permanencia).




Gráfico 1. Comparativa de matrices de confusión. Elaboración propia

En la tabla comparativa de métricas, se aprecia que **XGBoost** destaca como el modelo más sólido, alcanzando un *Accuracy* de 95,3%, *Recall* de 100% y *AUC-ROC* cercano a 1 (0,9898), lo que indica una excelente capacidad para diferenciar entre empleados que abandonarán y los que permanecerán. Random Forest también obtiene resultados muy sólidos (*AUC-ROC* 0,9898), mientras que la Regresión Logística, aunque aceptable (*AUC-ROC* 0,9254), es menos precisa.

=== Tabla comparativa de métricas ===

	Modelo	Accuracy	Precision	Recall	F1	AUC-ROC
0	Regresión Logística	0.813953	0.823529	0.736842	0.777778	0.925439
1	Random Forest	0.930233	0.900000	0.947368	0.923077	0.989035
2	XGBoost	0.953488	0.904762	1.000000	0.950000	0.997807

Estas métricas respaldan la elección de XGBoost como el modelo más adecuado, ya que minimiza los errores más críticos (confundir un abandono con una permanencia) y minimiza la identificación de empleados que se quedan o se marchan.

3.2 Probabilidades de abandono obtenidas

Tras entrenar los modelos, se calcularon las probabilidades de abandono para cada empleado de la organización. Estas probabilidades representan la predicción individual de riesgo de baja laboral, expresada en un rango de 0 a 1, donde valores más cercanos a 1 indican mayor probabilidad de abandono, tal como se muestra a continuación:

	Referencia	prob_abandono	perfil_activo
0	TRB-0000002	0.003458	1
2	TRB-0000007	0.002170	1
3	TRB-0000008	0.012615	1
4	TRB-0000009	0.008244	1
5	TRB-0000010	0.007375	1
...	...	...	...
206	TRB-0000243	0.021200	1
207	TRB-0000246	0.029211	1
208	TRB-0000247	0.264005	1
209	TRB-0000248	0.068995	1
210	TRB-0000249	0.097560	1

92 rows x 3 columns

Tabla 1. Probabilidad de abandono por trabajador. Elaboración propia

3.3 Segmentación de riesgo (bajo, medio, alto)

La distribución de estas probabilidades muestra que la mayoría de los/as trabajadores/as presentan un riesgo bajo, mientras que un pequeño grupo concentra valores altos, convirtiéndose en el principal foco de atención para la dirección de RR.HH. Como vemos en los siguientes gráficos, un 90% de la plantilla presenta riesgo de abandono bajo (scoring por debajo de un 10%), un 7% tiene un riesgo medio (scoring entre un 10 y un 20%), mientras que un casi un 4% tiene un riesgo de abandono elevado (scoring más de 20% de abandono), marcado en color rojo.




Gráfico 2. Antigüedad vs prob_abandono. Elaboración propia

4. Análisis de Influencia de Variables

Este apartado analiza las variables que más influyen en la predicción del abandono laboral, empleando la técnica de interpretación SHAP (Shapley Additive Explanations) aplicada al modelo seleccionado (XGBoost). La finalidad de este análisis es identificar los factores clave que incrementan o reducen la probabilidad de salida de los/as trabajadores/as.

4.1 Interpretación con valores SHAP

Cada valor SHAP representa la contribución de una característica a la predicción individual.

- Valores SHAP positivos: aumentan la probabilidad de abandono
- Valores SHAP negativos: la reducen.

4.2 Principales factores que influyen en el abandono (SHAP values)

A partir de los valores SHAP, se identificaron las siguientes variables como las más determinantes en la predicción de abandono:

- **Salario mensual** es la variable con mayor influencia: valores bajos tienden a incrementar la probabilidad de abandono, mientras que salarios más altos la reducen.
- **Edad y satisfacción laboral** también tiene un peso relevante: trabajadores/as más jóvenes y con menor satisfacción muestran mayor tendencia a abandonar.
- **Antigüedad y promociones internas** presentan una relación moderada: menor antigüedad y escasas oportunidades de promoción se asocian con mayor riesgo.
- Otras variables como **distancia al trabajo y grupo profesional** tienen un impacto más limitado, pero no despreciable.
- El modelo confirma que **factores económicos y de desarrollo profesional son los principales impulsores de la decisión de marcharse.**




Gráfico 3. Valores SHAP. Elaboración propia

4.3 Variables destacadas

Los/as trabajadores/as con baja satisfacción, baja antigüedad y salario inferior al promedio muestran consistentemente altos valores SHAP positivos, indicando un mayor riesgo de abandono.

En contraste, trabajadores/as con más promociones y mayor tiempo en la organización presentan valores SHAP negativos, que actúan como factores protectores.

5. Conclusiones y Recomendaciones

5.1 Conclusiones clave

El análisis realizado confirma que la predicción de abandono laboral mediante modelos de Machine Learning es factible y precisa. Entre los modelos evaluados, **XGBoost fue el que mejor desempeño mostró (AUC-ROC = 0.99, Recall = 100%)**, permitiendo identificar con gran exactitud a los/as empleados/as con mayor riesgo de abandono.

Los factores económicos (salario), la edad, la satisfacción laboral y antigüedad fueron los más determinantes en la decisión de permanecer o abandonar la empresa. Además, se ha evidenciado que la rotación se concentra en perfiles con **menor experiencia y menor nivel de promoción interna**.

5.2 Impacto económico estimado

El estudio revela que la reducción de la fuga de empleados tiene un alto impacto financiero positivo. En términos económicos:

- Reducir la fuga en un 10% supondría un ahorro de 61.316€ anuales.
- Reducir la fuga en un 20% generaría un ahorro de 122.633€ anuales.
- Reducir la fuga en un 30 % permitiría ahorra hasta 183.949€ al año.

Estos valores reflejan el potencial de ahorro derivado de estrategias de retención basadas en datos.

5.3 Recomendaciones estratégicas para reducir el abandono

- **Revisión salarial focalizada** en trabajadores/as de mayor riesgo (identificados por el modelo).
- **Fortalecimiento de planes de carrera y promoción interna**, especialmente para trabajadores/as con baja antigüedad.
- **Programas de mejora de satisfacción laboral**, priorizando equipos y departamentos más afectados.
- **Monitoreo continuo mediante dashboard dinámico**, para actuar de forma preventiva.

5.4 Posibles mejoras y trabajo futuro

- Ampliar la base de datos incorporando más años y variables (evaluaciones de desempeño, formación continua, clima laboral).
- Implementar análisis en tiempo real, integrando el modelo con los sistemas de RR.HH.
- Evaluar la rentabilidad de las estrategias de retención implementadas mediante un análisis coste-beneficio, comparando la inversión necesaria para reducir la fuga de talento con el ahorro estimado en costes de contratación y sustitución.
- Uso de redes neuronales y modelos avanzados de Deep Learning.

6. Bibliografía

- The true cost of Hiring an Employee in 2024:
<https://toggl.com/blog/cost-of-hiring-an-employee>
- The real cost of losing an Employee:
<https://peopleforce.io/es/blog/el-verdadero-costo-de-perder-a-un-empleado>
- El costo medio de reemplazar a un empleado en España:
<https://www.ricoh.es/noticias-eventos/noticias/el-coste-medio-de-reemplazar-a-un-empleado-en-espana-asciende-a-7400eur/>
- El verdadero coste de no tener estrategia de retención de talento:
<https://www.goconqr.com/es/blog/retencion-de-talento/>